

[会议](#) > [2019 IEEE国际会议...](#) [2019 IEEE国际会议...](#) > [2019 IEEE国际会议...](#) > [2019 IEEE国际会议...](#) > [2019 IEEE国际会议...](#) > [2019 IEEE国际会议...](#) > [2019 IEEE国际会议...](#)

使用MR图像表征和检测阿尔茨海默氏病的多尺度深度卷积网络

发行人: IEEE

引用这个

Cite This

 PDF格式

[<< Results](#) | [< Previous](#) | [Next >](#)

4 作者 葛晨杰; 启x区; 艾琳宇花菇; Asqeir商店Jakola 所有作者

155
充分
文字检视

Export

to
Collabratec

Alerts

Manage
Content
Alerts
Add to
Citation
Alerts

更像这样

轻度认知障碍和阿尔茨海默氏病的定量MRI
脑研究：方法学综述
IEEE生物医学工程评论
发布时间：2018年

基于M / EEG的生物标记物预测MCI和阿尔茨海默氏病：从ML角度回顾
IEEE生物医学工程学报
发布时间：2019年

显示更多

本文中提及的具有专利技术的顶级组织

Organization Type	Count
ORGANIZATION 4	10
ORGANIZATION 3	8
ORGANIZATION 2	6
ORGANIZATION 1	4

抽象	
文件部分	<div> <div>Dowri</div> <div>PDF</div> </div>
1. 介绍	
2. 建议的广告检测方法	<div> <div>Abstract:</div> <div>This paper addresses the issues of Alzheimer's disease (AD) characterization and detection from Magnetic Resonance Images (MRIs). Many existing AD detection methods use s...</div> <div>View more</div> </div>
3. 实验结果	
4. 结论	
作者	<div> <div>Metadata</div> <div>抽象:</div> <div> <p>本文讨论了阿尔茨海默氏病 (AD) 表征和磁共振图像 (MRI) 检测的问题。许多现有的 AD 检测方法都使用来自脑部扫描的单尺度特征学习。在本文中，我们提出了一种用于学习 AD 功能的多尺度深度学习架构。本文的主要贡献包括：(a) 针对 AD 检测的专用任务提出了一种新颖的 3D 多尺度 CNN 架构；(b) 提出多尺度特征的特征融合和增强策略；(c) 对几种设置的影响进行实证研究，包括两种数据集分区方法，以及多尺度和特征增强的使用。在开放的 ADNI 数据集上进行了实验（对 337 名受试者进行了 1198 次脑部扫描），测试结果表明该方法的有效性，测试精度为 93。在受试者分离的数据集上分别为 53%，87.24%（最佳，平均）和在随机脑扫描分区的数据集上分别为 99.44%，98.80%（最佳，平均）。与八种现有方法的比较为该方法提供了进一步的支持。</p> </div> </div>
数据	
参考文献	
关键词	
指标	
More Like This	<div> <div>发表于:</div> <div>2019 IEEE 国际图像处理会议 (ICIP)</div> </div>
脚注	<div> <div>会议日期:</div> <div>2019 年 9 月 22-25 日</div> <div>INSPEC 登录号:</div> <div>19212578</div> </div>
	<div> <div>加入 IEEE Xplore 的日期:</div> <div>2019 年 8 月 26 日</div> <div>DOI:</div> <div>10.1109 / ICIP.2019.8803731</div> </div>

Contents

第1节。 介绍

阿尔茨海默氏病(AD)是一种以各种方式影响人们的进行性脑部疾病。通过破坏脑细胞,AD逐渐导致记忆力和思维能力的丧失。最终,患者甚至无法执行最简单的任务。因此,AD的检测和治疗非常重要。现有的一些用于AD的医学评估技术包括身体和神经生物学检查,迷你精神状态检查(MMSE)。最近,由于早期治疗或干预的可能性,使用脑部MR图像检测AD已引起更多关注。为了检测AD患者,除其他临床症状外,通常还使用MR图像。通常通过提取与疾病相关的独特特征来对MR图像进行AD表征,

根据通过手工设计技术还是通过自动方法提取特征的方式,特征学习/提取方法可以大致分为两个范例。前者通常与分析或基于模型的方法有关,而后者与深度学习方法有关。由于手工制作的功能很大程度上依赖于人类专家的知识,因此通过深度学习方法自动学习功能已经引起了人们的极大兴趣。对于AD检测,通过使用这些范例下的方法,存在许多有希望的作品。Tong等。[1]提出了一种多实例学习策略,以使用MRI体素袋和图形映射袋对痴呆症和特征进行分类。刘等。[2]建议使用选定的模板提取多视图特征。然后,通过在每个视图空间中对主题进行聚类来获得编码功能,然后通过一组SVM对主题进行分类。对于深度学习方法,Bäckström等。[3]提出了一种用于AD检测的高效且结构简单的3D CNN,在包含约340个主题的相对较大的数据集上获得了良好的结果。萨拉夫等人[4]使用CNN架构LeNet和GoogleNet通过sMRI和fMRI脑部扫描来检测阿尔茨海默氏病。[5],[6]提出了在具有不同尺寸的补片,或具有低和正常分辨率的图像过滤器使用细胞神经网络MRI图像分割。通过预先选择具有三个固定补丁大小的CNN[5],或者使用[6]中的低分辨率和正常分辨率图像,获得了基于多尺度的分割。尽管这些方法很有前途,但在投入临床使用之前仍需要进一步的改进。可能妨碍上述方法的鲁棒性能的一个问题是,它们仅使用单尺度特征来表征AD。可以看出,AD特征不仅存在于详细的体素级别中,而且还存在于反映AD中组织结构变化的语义级别中(例如,较大的CSF区域,GW和WM中的细节丢失以及更多)。

基于以上原因,我们提出了一种新颖的3D多尺度CNN架构,可使用MR图像检测阿尔茨海默氏病。所提出的方法基于以下观察结果:大脑扫描中的组织可能在规模和结构上有所不同。因此,将多尺度特征学习合并到深度卷积网络中可能会导致学习详细的组织特征(在多个尺度上)以及语义特征,这对于阿尔茨海默氏病的表征非常有效。为了充分利用多尺度特征,将融合和增强策略应用于细化和组合不同尺度的特征。这些比例尺中的要素将单独合并以形成多比例尺要素图。

第2节。 建议的广告检测方法

所提出的AD检测方法背后的基本思想是将多尺度特征学习纳入到深度卷积网络体系结构中,以通过MRI表征阿尔茨海默氏病。这是由于多尺度特征在语义和体素级别信息上均很丰富而引起的,因此可能导致AD的特征性更具代表性。在提出的方法中,首先对3D MRI进行预处理,然后再使用新颖的3D多尺度卷积网络(3D MSCNN)提取不同尺度的特征。然后,通过串联将这些特征融合在一起,通过增强将这些特征融合在一起,然后再进行完全连接的层进行分类。图.1图2显示了所提出方法的框图,其中最后三个块的详细信息在图2中进一步进行了概述。




图. 1
拟议方法的管道。

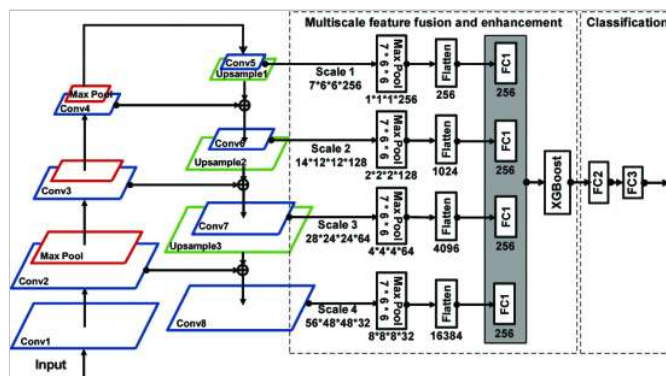


图2。
图1中的特征提取，融合和增强以及分类的详细信息（块2-4）。

在下文中，我们将详细描述所提出的方法。

2.1. 数据预处理

预处理是必不可少的步骤，它将大大影响AD检测的性能。预处理包括三个步骤：皮层重建，图像大小归一化和强度归一化。步骤*皮质重建*由数据集提供者进行的，虽然人们也可以执行该步骤通过使用*侦察-所有*从*FreeSurfer*软件包[7]包含一组处理诸如运动校正的和符合的，非均匀的强度归一化，塔莱拉什变换计算，强度归一化，颅骨和颈部切除。步长*图像尺寸归一化*包括通过根据数据集中最大的大脑大小修剪3D图像，然后将每个修剪的3D图像调整为预先选择的大小（在我们的测试中为112 x 96 x 96像素），来消除大脑组织外部的过多背景图像量。选择标准化大小是在可用GPU内存，计算成本和使用低分辨率3D图像可能导致的性能下降之间进行权衡。

2.2. 3D MSCNN架构和特征选择

如图2所示，3D多尺度卷积神经网络（MSCNN）图层以及特征融合和增强层用于提取多尺度特征。在训练期间，这些步骤用于学习网络模型和与特征提取有关的系数。

多尺度卷积网络层：

所提出的MSCNN由8层（Conv1-Conv8）组成，其中最后3层（Conv6-Conv8）是从“跳过连接”获得的，如图2所示。前5个卷积层生成从粗到细比例的特征图。卷积层2、3、4的自下而上的路径的输出分别添加到卷积层7、6、5的上采样路径的上采样路径（乘以2）。

功能融合和增强层：

如图2所示，特征融合和增强层将多尺度特征图融合为一个向量。在融合之前，每个特征图都被单独合并，以便不同比例的特征图可以保持不同的分辨率。通过连接所有比例级别的特征向量，应用了一种简单的特征融合策略来融合多尺度特征。为了进一步增强特征并减小特征维，然后采用基于梯度增强的机器学习方法XGBoost [8]，其中根据特征在AD表征中的重要性对特征进行排名。仅选择具有高重要性的特征分量以形成最终特征向量。

分类层：

分类器包括2个完全连接的层，其中softmax用作最后一层的激活函数。

备注：

MSCNN体系结构不同于U-net [9]，因为自上而下的路径层的输入是由自下而上的路径输出和上采样的自上而下的路径输出之和形成的。此外，该体系结构与[10]中的相似。但是，在卷积滤波器大小和后续层方面（例如在合并图层之前使用3 * 3 * 3卷积滤波器）方面有所不同，此外，以相同比例合并来自不同比例上采样和卷积的多尺度特征图，以获得不同的大小所有比例的要素地图。此外，添加了特征融合和增强步骤，以获得最终的

特征向量，其中在不损害性能的情况下显着减小了多尺度特征向量的维数。该方法也不同于[5]，[6]中的多尺度概念。用于MRI分割，其多尺度是通过选择3种不同流中的固定斑块大小或低/正常分辨率MRI进行训练而获得的，而提出的方法中的多尺度概念的获取方式与多尺度小波分析中的相似，但是通过深度学习方法。

第3节。
实验结果

3.1。建立

带有TensorFlow [12]后端的KERAS库[11]用于网络培训。所有实验均在配备Intel-i7 3.40GHz CPU，48G RAM和NVIDIA Titan XP 12GB GPU的工作站上进行。网络权重是使用Adam学习的优化器。通过通过实验仔细调整网络来选择超参数：训练的纪元数设置为150；使用分步学习率，其中将学习率设置为将时期 $\in [1, 50]$ 设置为0.001，将时期 $\in [51, 100]$ 设置为0.0001，将时期 $\in [101, 150]$ 设置为0.00001。将扁平层和串联层中使用的丢失率设置为0.5。对于除输出层以外的所有层，都使用L2正则化和正则化参数0.00005。使用批处理，其中批大小设置为8，批归一化动量值设置为0.9。所有层的初始化方法均选择为glorot_uniform。

数据集：本实验中使用的ADNI数据集来自阿尔茨海默氏病神经影像学计划[13]。在我们的实验中，使用2类（AD和NC）的T1 MRI扫描进行分类。数据集的详细信息在表1中给出。从表1中可以看出，每个对象可能包含不同时间的几次扫描（平均3.5次）。

表1. 用于我们的实验的ADNI数据集。女性/男性：男/女，包括四个年龄段： (≤ 60) / $[60,70)$ / $[70,80)$ / $[\geq 80]$

Class	# Subjects (F/M)	Age group	#3D Scans
AD	198 (95/103)	(9/35/92/62)	600
NC	139 (66/73)	(0/5/108/26)	598
Total	337 (161/176)	(9/40/200/88)	1198

3.2。数据集分区和方法

然后将整个数据集划分为70%，15%，15%，分别形成训练集，验证集和测试集。应用了与两个案例研究相关的两种数据集分区策略：案例A和案例B。

在案例A研究中，我们将数据集随机分为两个子集，即训练+验证和测试，其中，脑部扫描根据随机选择的主题进行划分。这意味着来自同一主题的不同扫描只会最终出现在训练或测试子集中，而不会同时出现在两者中。这种划分策略与临床方案和实用性更相关。

在Case-B研究中，使用了第二种分区策略，其中根据随机选择的脑部扫描对训练，验证和测试子集进行了分区，而与受试者无关。案例B的研究在临床上不那么相关，但是，与其他现有方法相比，该研究使我们能够对所提出的方法有所了解。

3.3。结果

为了测试该方法的有效性，我们对案例A和案例B进行了实验。

案例研究的结果：

为了测试该方法的有效性，使用主题分隔的数据集分区方法对数据集进行了案例研究。图3显示了训练和验证中总体准确性和损失与历时的关系。




图3。

在案例研究中，使用主题分隔的数据集分区对提议的方案进行分类的性能。左：准确性与时代；正确：损失与时代。

观察图3，可以看到训练和验证在100个时期后或多或少地收敛了。与训练相比，验证中的性能下降，表明可能是过度拟合，可能是由于所用数据集的大小相对中等。

为了评估所提出方法的性能，表2（a）显示了5次运行测试集的性能。在每次运行中，都根据受试者将数据集再次随机重新分区。为了进一步检查各个类别的性能，表2（b）显示了根据一次选择的运行在测试集上的混淆矩阵。

表2. 案例研究的测试性能，其中数据集是根据随机分离的受试者进行划分的。

Run	1	2	3	4	5	Average ($ \sigma $)
Accuracy (%)	91.28	82.95	85.64	93.53	82.78	87.24 (4.40)

(a) Overall accuracy (on AD and NC) on testing sets and averaged result.

True \ classified	AD (%)	NC (%)
AD (%)	95.51	4.49
NC (%)	8.64	91.36

(b) Confusion matrix for individual classes on the testing set (from the best result in run 4).

观察表2（a），提出的方案具有相当好的测试精度，在5次运行中最高93.53%，平均87.24%。由于使用的数据集大小适中，因此标准偏差相对较大，因此要素统计信息的分布相对较差。从表2（b）可以看出，两类（AD和NC）的性能相对平衡，其中AD的检测率略高，为95.51%，误报率则为8.64%。

案例B的研究结果：

本案例研究旨在通过与基线方法和几种现有方法进行比较来进一步检验所提出方法的有效性，即使案例B研究在临床上不那么重要。表3（a）显示了根据大脑扫描对数据集进行随机划分时，该方法的测试性能。在这5次运行中的每一次中，数据集都会再次随机重新分区。为了检查各个类别的性能，表3（b）显示了最佳运行（运行5）的测试集上的混淆矩阵。

表3. Case-B研究的实验结果，其中数据集是根据脑部扫描随机分配的。

Run	1	2	3	4	5	Average ($ \sigma $)												
Accuracy	99.00	98.33	98.33	98.89	99.44	98.80 (0.42)												
(a) overall accuracy (on AD and NC) on testing sets.																		
<table><tr><th colspan="2">True \ classified</th><th>AD</th><th>NC</th></tr><tr><th colspan="2">AD</th><td>98.89 %</td><td>1.11%</td></tr><tr><th colspan="2">NC</th><td>0.01%</td><td>99.99 %</td></tr></table>							True \ classified		AD	NC	AD		98.89 %	1.11%	NC		0.01%	99.99 %
True \ classified		AD	NC															
AD		98.89 %	1.11%															
NC		0.01%	99.99 %															
(b) confusion matrix for individual classes on the test set (in run 5).																		

观察表3（a），提出的方案在测试集上产生了非常高的准确性（5轮运行中最高99.44%和平均98.80%，标准偏差为0.42小）。从表3（b）中还可以看到，来自2类的结果很平衡，其中误报率非常低（0.01%）。与案例A的结果相比，这不足为奇，因为来自同一受试者的不同扫描（尽管彼此之间可能存在高度相关性，但可能在训练和测试子集中都可能具有很高的相关性）。

3.4。通过经验检验进行分析

进行了两个测试，以检查提出的方法中不同部分的影响，如下所述。

特征增强的影响：为了检验特征融合和增强部分的有效性，表4显示了特征增强前后特征向量的维数。观察表4，在不影响测试性能的情况下，特征向量的尺寸显着减小（减小到其原始大小的19.0%）。

表4. 功能融合和增强：尺寸减小。

Feature vector	After fusion	After XGBoost
Dimension	1024	195

多尺度特征的影响：为了检验使用多尺度特征的影响，我们将提出的方法与基准3D CNN方法[3]进行了比较，该方法的结果在测试集上，使用对象

分隔的划分方法在同一数据集上进行（请参见表1），并且在两种情况下都使用了最佳结果。从表5可以看出，采用建议的方法可以将测试性能提高3.42%。

表5. [3]中提出的方案与基准3D CNN方法之间的比较。

Method	3D CNN	Proposed
Test accuracy (%)	90.11	93.53

3.5。与最先进方法的比较

我们使用八种最先进的方法进行了性能比较，并指出这种比较只能表示*相对性能*，因为数据集中的大小和扫描次数以及每个受试者的脑部扫描次数在这些方法。表6显示了来自八种现有方法的结果，其中在所提出的方法中仅显示了最佳运行结果，因为大多数现有方法未显示出多个测试结果/统计信息。

表6. 所提出的方法与8种现有最先进方法的比较，以指示相对性能。

Method	# Subjects AD/NC/MCI	# Scans AD/NC/MCI	Accuracy (%) AD vs. NC
Deep AD [4]	211/91/-	5:1 AD/NC	98.84
3DAECNN [14]	70/70/70	-	97.60
AE+ [15]	65/77/169	-	87.76
SAE [16]	200/232/411	755/1278/2282	94.74
ICA [17]	202/236/410	-	85.70
MIL [1]	198/231/405	-	88.80
3DCNN [3]	198/139/-	600/598	98.74
Proposed	198/139/-	600/598	99.44
(a) using random partition according to MRI scans.			
Method	# Subjects AD/NC/MCI	# Scans AD/NC/MCI	Accuracy (%) AD vs. NC
SAE-CNN [18]	755/755/755	755/755/755	95.39
3DCNN [3]	198/139/-	600/598	90.11
Proposed	198/139/-	600/598	93.53
(b) using random partition according to subjects.			

表6中的结果表明，所提出的方法取得了相对较好的性能，而且SAE-CNN [18]在大型数据集上具有最佳性能，每个对象一次扫描。

讨论：

该方法在中等数据集上进行了测试，可下载以供公众使用。我们没有使用数据增强，因为通过左右脑图像翻转进行的简单增强并未导致测试中性能的提高。需要使用主题分隔的数据集分区进一步提高性能，例如，通过使用大型数据集或鲁棒的增强方法来增加训练数据集。

第4节。
结论

拟议的阿尔茨海默氏病检测方法，使用3D多尺度CNN，然后进行特征融合和增强，已经在中等ADNI数据集上进行了测试（来自337名受试者的1198次扫描）。我们的测试结果表明，所提出的方法对于学习和表征阿尔茨海默氏病的区别特征是有效的。提出的方案使用主题分离的数据集，在AD和NC类上获得了良好的分类性能（5次运行中最佳93.53%，平均87.24%）。与8种现有方法的比较表明，该方法有望用于AD检测。未来的工作将是使用来自扩充或测量数据的大型数据集来进一步改善性能，以及在实验中添加轻度认知障碍（MCI）主题类，

作者	▼
数据	▼
参考文献	▼
关键词	▼

指标	▼
脚注	▼

IEEE个人帐户

更改用户名/密码

采购明细

付款方式
查看购买的文件

档案信息

通讯首选项
职业与教育
技术兴趣

需要帮忙?

美国和加拿大: +1 800 678 4333
全球: +1 732 981 0060
联系与支持

跟随



关于IEEE *Xplore* | 联系我们 | 帮助 | 无障碍 | 使用条款 | 非歧视政策 | 网站导航 | 隐私权和退出Cookie
IEEE是一个非营利性组织，是世界上最大的技术专业组织，致力于为人类的利益而发展技术。

©版权所有2020 IEEE-保留所有权利。使用本网站表示您同意条款和条件。

IEEE Account

» Change Username/Password
» Update Address

Purchase Details

» Payment Options
» Order History
» View Purchased Documents

Profile Information

» Communications Preferences
» Profession and Education
» Technical Interests

Need Help?

» **US & Canada:** +1 800 678 4333
» **Worldwide:** +1 732 981 0060
» Contact & Support

About IEEE *Xplore* | Contact Us | Help | Accessibility | Terms of Use | Nondiscrimination Policy | Sitemap | Privacy & Opting Out of Cookies

A not-for-profit organization, IEEE is the world's largest technical professional organization dedicated to advancing technology for the benefit of humanity.
© Copyright 2020 IEEE - All rights reserved. Use of this web site signifies your agreement to the terms and conditions.