



---

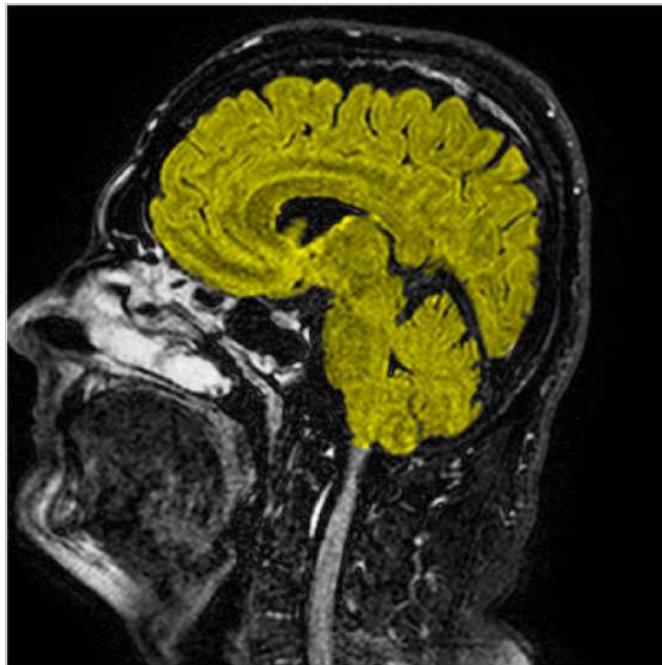
## Contents

---

### 第一节 介绍

磁共振成像是现代且广泛使用的放射学方法，用于显示人体的内部器官。使用MRI，可以获得人体特定区域的切片，可以对其进行进一步处理并将其链接到所需器官的3D图像上。MRI在诊断放射学方面比其他成像方法的优势在于，大多数器官的准确性更高，这是不同软组织中信号强度不同的结果。此特性使其成为用于对人脑成像的理想诊断工具—无论是用于组织的组织还是用于发现和测量异常区域的组织。

即使对于有经验的放射科医生来说，在MRI扫描上分割人脑组织也是一项耗时的工作。因此，此过程的自动化非常有价值，并且可以在几秒钟内为他们呈现精确分割的大脑时，帮助医生更快地确定正确的诊断。自动分割医学中任何组织的问题是，解决方案必须可靠并且至少与医生独自完成相同任务时一样精确。我们的解决方案在真实数据上可提供良好的结果，并且是帮助医生自动化日常繁琐任务并提供有关患者进展的客观特征的一小步。



图。1。  
MRI矢状脑扫描切片的示例-用我们的系统分割的脑组织以黄色突出显示。

---

本文的其余部分的结构如下。在第二部分中，我们分析了现有的脑组织分割方法，并简要列出了深度学习分割领域中的相关工作。在第三节中，我们描述了有关用于训练和评估我们提议的网络结果的数据的所有信息。在第三部分的B 小节中，我们描述了如何将数据准备为神经网络的输入，以及如何处理有限数量的GPU内存。第四部分包含有关神经网络体系结构的所有信息，我们包括了带有源代码的github存储库的链接，因此可以轻松地重复进行此工作。在第五节 我们解释结果并描述使用的指标。

### 第二节 相关作品

#### A. 脑分割方法

在深度学习算法成为语义分割的标准之前，已经很好地研究了自动脑组织分割的问题。Despotović等人[1]概述了较旧的方法，例如阈值化，聚类或某种形式的简单机器学习算法。这些方法也像[2]一样严重依赖图像预处理，因此它们不是自动的。一种非常常用的预处理方法是某种形式的颅骨剥离算法，该算法在进行处理之前就从输入图片中删除了颅骨的骨组织，如[3]中所述。由于深度学习方法即使不对输入图像进行任何预处理也能实现更高的准确性，因此包括本文在内的大多数正在进行的研究现在都在使用某种形式的深度神经网络进行脑分割。[4]中可以找到使用深度学习进行脑分割领域的最新技术概述。

### B.深度学习细分方法

如我们在前面的小节中所述，用于分割图像数据的最新技术方法是基于深度学习的。[5]中比较了当前使用的网络体系结构。Shelhamer等。[6]提出了第一种用于分割的全卷积架构。最受欢迎的体系结构之一是称为U-Net的网络的自动编码器类型[7]。它由下采样，桥接和上采样模块组成，由于与同类竞争产品相比，它只需使用很少的数据即可进行适当训练的能力，因此被广泛地用于分割医学数据[6]。分类网络领域的发展，使用了从粗糙网络到精细网络的数据互连，就像在剩余网络中一样[8]紧随其后的是密集连接的网络[9]，导致该原理也应用于分段网络。使用这些原理的流行的分割架构是提拉米苏网络[10]。所有引用的体系结构都是为2D数据设计的。

我们的目标是设计具有紧密连接的层的U-net体系结构，以进行3D数据处理，并将其准确性与原始U-Net实现和具有附加残留连接的U-Net的结果进行比较。

## 第三节。 数据集

### A.数据概述

数据集包括来自不同患者的22次脑部扫描，每次扫描包含257个人脑矢状切片。MRI数据由布尔斯大学医院放射科提供，所有原始切片均由两名独立的人类专家标记，形成了两组适用于语义分割的地面真相掩模，将所有像素标记为脑组织（白色）或非像素脑组织（黑色）。

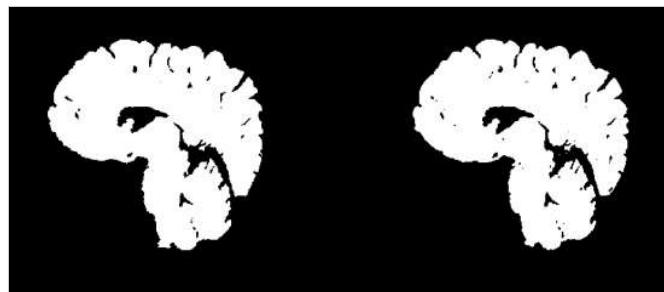


图2。  
参考地面真相蒙版由人类专家标记（左），蒙版由我们的系统标记（右）。

---

第一位专家非常准确，准确地标记了数据，这些标记用作培训和评估的参考数据。第二位专家标记了该数据，因为它在医学实践中每天定期进行。参考地面真值蒙版和由我们的系统标记的蒙版的示例可以在图2中看到。

### 数据准备

我们使用21次扫描作为训练数据，其中有10%用于验证。最后剩余的第22脑扫描用于测试数据。由于我们使用3D分割这一事实，并且我们希望一次使用尽可能多的切片来保留空间信息，但仍然能够在当前可用资源（GPU gtx 1080ti和11 GB RAM）上训练复杂的神经网络架构。），我们必须将数据分为16个切片的批次。由于每个受试者两端大约有15个切片仅由非脑组织组成，因此包含的信息价值很小，因此我们丢弃了每个受试者的最后一个切片，并且每次扫描仅使用了256切片，因此最终数目可被除以16。为了充分利用3D分割的优势，我们将训练数据集划分为重叠的批次。例子可以看图3

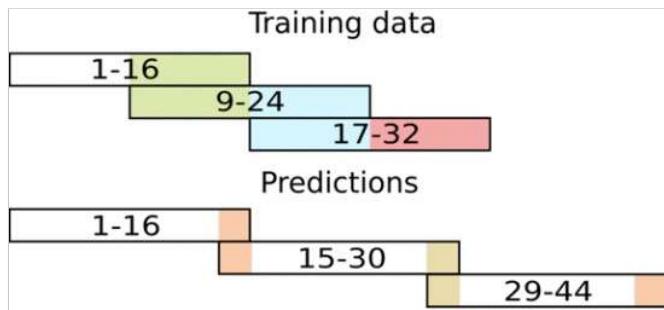


图3。  
训练和预测数据批量重叠的示例。数字显示每个批次包含哪些切片。

我们希望对系统的结果预测使用相同的重叠数据技术。但是为了减少系统预测结果所需的时间，我们在每个批次的每个末端仅重叠了2个像素。然后，预测由每个批次的中央14片组成。这产生用于预测的252张测试图像。

#### A. 神经网络架构

### 第四节 方法

在本文中，我们介绍了基于原始U-Net实现[3]的3D Dense-U-Net网络，但在处理相同特征尺寸的层之间增加了互连，其模型如图4所示。这有助于网络获得更快的学习曲线并获得更高级别的细节。它是一种自动编码器类型的体系结构[7]，它具有4个下采样和4个上采样块，它们由一个桥接块（在图4中是网络的最下部）连接。在通过每个下采样块后，其底部的maxpooling层将特征大小减半。在每个上采样块的开始，使用[11]所述的转置卷积层将特征大小加倍每个尺寸的步幅为2。通过使用零填充，可以通过互连传递信息。在每次卷积运算之后，我们用零填充新计算的向量至其原始长度，因此两个卷积层都使用相同大小的输入向量。

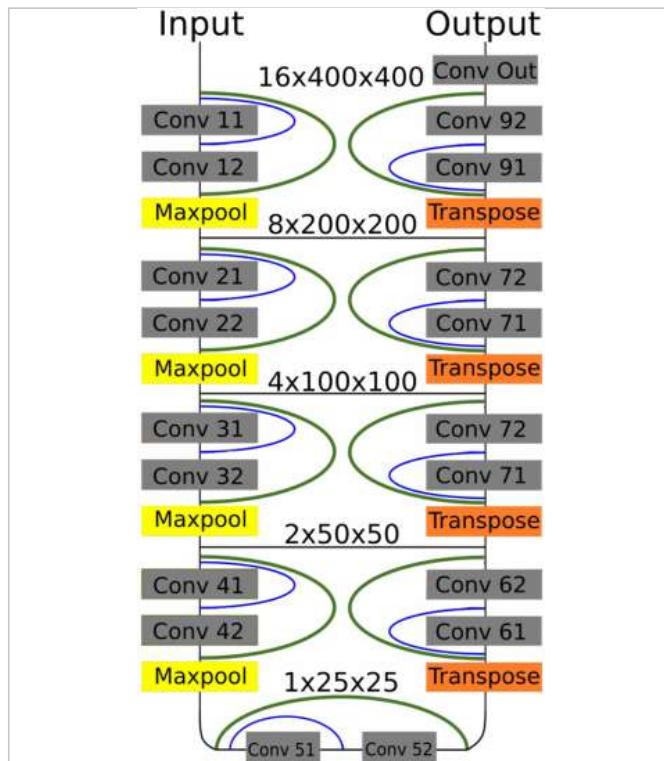


图4。  
密集-u-net网络模型。剩余互连为绿色，密集互连为蓝色。

表I.每层中神经元的数量

在我们的实验中，我们比较了原始U-Net和Residual-U-Net的结果，仅添加了残留互连（图4中的绿色）。考虑到其参数数量，尤其是Residual-U-Net网络具有非常好的结果。

## B. 实施细节

本文使用的完整源代码可在<sup>1</sup>获得。使用Tensorflow后端上的Keras 框架 [12]训练了所有神经网络体系结构。使用CUDA 8.0在具有11 GB内存的 nvidia gtx 1080ti图形卡上进行了培训。作为第一个U-Net模型的启发，使用了存储库[13]。我们的基本U-Net架构使用3D数据处理层。所有网络都使用二进制交叉熵作为损失函数。我们将Adam优化器与参数一起使用  
**学习率 =  $1e-5$** ，**beta 1 = 0.9**，**beta 2 = 0.999**，**epsilon =  $1e-08$**   
**和衰减 =  $1.99e-7$**  使用衰减参数，我们将每个时期的学习率参数降低恒定值。

表二。网络层的参数-卷积内核大小，步幅和激活函数。

Downsampling block			
Layer type	Kernel (pool) size	Strides	Activation
Convolution 3d	3,3,3	0,0,0	Relu
Convolution 3d	3,3,3	0,0,0	Relu
Maxpooling	2,2,2	0,0,0	-
Upsampling block			
Layer type	Kernel (pool) size	Strides	Activation
Transpose Conv.	2,2,2	2,2,2	-
Convolution 3d	3,3,3	0,0,0	Relu
Convolution 3d	3,3,3	0,0,0	Relu
Bridge block			
Layer type	Kernel (pool) size	Strides	Activation
Convolution 3d	3,3,3	0,0,0	Relu
Convolution 3d	3,3,3	0,0,0	Relu
Output convolution			
Layer type	Kernel (pool) size	Strides	Activation
Convolution 3d	1,1,1	0,0,0	Sigmoid

通过向默认的3D U-Net体系结构添加互连，我们创建了Residual-U-Net 和Dense-U-Net体系结构。残余U-Net仅在整个下采样或上采样块上使用互连，如图4所示，残余互连为绿色。Dense-U-Net同时使用残差和密集互连（图4中的蓝色），这些互连将未处理的信息传递到下采样块和上采样块的中间层。

网络将范围[0, 1]用作输入数据值。数据必须相应地在输入和输出上转换，因为原始图像被编码为png格式的8位单色图像，并且其像素值在[0, 255]范围内。当我们在输出网络层上使用S型激活时，网络并不仅将所有像素标记为0和1，而且还标记为之间的某些值。因此，我们仅将其用作预测数据阈值的后处理。值小于0.5的所有像素均标记为0，值大于1的像素。

我们首先针对50个时期训练了这三个网络，以进行评估。然后，我们将 Dense-U-Net训练了99个时期，以获得最终结果，因为它在所有三个评估网络中均取得了最佳结果。

## 第五节 结果

我们使用了五个不同的指标进行评估，因此我们可以轻松地将结果与类似作品进行比较。将所有测得的指标与人类专家标记的口罩尽可能精确地进行比较。首先使用的指标是像素精度，其等式为（1）其中 $\tilde{n}_{TP}$ 代表真正的积极， $\tilde{n}_{TN}$ 真正的负面， $\tilde{n}_{FP}$ 误报和 $\tilde{n}_{FN}$ 假阴性。

$$\text{P}(\bar{X}, Y) = \frac{\tilde{n}_{TP} + \tilde{n}_{TN}}{\tilde{n}_{TP} + \tilde{n}_{TN} + \tilde{n}_{FP} + \tilde{n}_{FN}} \quad (1)$$

$$d(X, Y) = \frac{2 * |X \cap \bar{Y}|}{|X| + |\bar{Y}|} \quad (2)$$

$$\text{IoU}(X, Y) = \frac{|X \cap \bar{Y}|}{|X \cup \bar{Y}|} = \frac{|X \cap \bar{Y}|}{|X| + |\bar{Y}| - |X \cap \bar{Y}|} \quad (3)$$

[查看资料](#)

**表III。**比较已测试的u-net版本。使用的指标-像素精度，骰子系数，并集交集，平均hausdorff距离[voxel]和roc曲线下的面积。

Metric	Dense-Unet	Res-Unet	Unet	Human
P.A.	0.99703	0.99662	0.99619	0.99489
Dice c.	0.98843	0.98686	0.98514	0.98033
I.o.U.	0.97713	0.97407	0.97072	0.96141
A.H.D.	0.01334	0.01911	0.02427	0.02479
A.u.R.C.	0.99439	0.99353	0.99205	0.98325

骰子系数[14]在等式（2）中，并且交集在联合[15]上，也称为Jaccard指数在等式（3）上。X和Y代表第一个和第二个比较蒙版上的一组正像素。我们使用内脏分割工具[15]计算所有指标的结果。

如第三节所述，我们计算了对所有252个切片的最后22次脑部扫描的预测。该扫描未用于训练，因此我们的结果表明了我们的方法在看不见的数据上的可靠性。我们将预测数据与人类专家在标准医学实践中标记的口罩进行了比较，如表III所示。在“人类”栏中。在表三中可以看到所有三个网络的结果比较。

在所有指标中，Dense-U-Net网络均具有最佳结果，但即使使用基本的U-Net网络进行分段，也比人工标记的蒙版具有更好的结果。我们再次对其进行99个时期的训练，以获取最终结果，这些结果列在表IV中。

经过适当培训的Dense-U-Net像素精度比人类提高了0.2%以上。

结果表明，即使在不属于训练数据集的真实数据上，该方法也能比人类专家获得更高的准确性。

## 第六节 结论

我们介绍了升级的U-Net架构，其中包括为3D数据处理而修改的密集连接层，即3D Dense-U-Net。该网络对测试数据的像素精度达到了99.70%，超过了人类专家在标准医学实践中所做的99.49%的精度。

我们的方法可以轻松地应用于已经使用U-Net架构的任何细分方法。产生的源代码已发布，其链接在IV节中。

使用本章数据集中介绍的数据准备技术，我们能够使用具有11 GB RAM的GPU训练具有3D数据的深度神经网络。

**表四**与人工专家结果相比，密集型u-net网络的最终结果。使用的指标-像素精度，骰子系数，并集交集，平均hausdorff距离[voxel]和roc曲线下的面积。

Metric	Dense-Unet	Res-Unet	Unet	Human
P.A.	0.99703	0.99662	0.99619	0.99489
Dice c.	0.98843	0.98686	0.98514	0.98033
I.o.U.	0.97713	0.97407	0.97072	0.96141
A.H.D.	0.01334	0.01911	0.02427	0.02479
A.u.R.C.	0.99439	0.99353	0.99205	0.98325

Metric	Dense-Unet	Human
P.A	0.99705	0.99489
Dice c.	0.98852	0.98033
I.o.U.	0.97731	0.96141
A.H.D.	0.01287	0.02479
A.u.R.C.	0.99467	0.98325

将来，我们计划进一步升级数据准备技术，以便能够训练更密集的互连体系结构，计划在其他公共可用数据集上评估我们的方法，并设计一种更通用的数据准备技术，该技术甚至适用于许多输入的图像不能被16整除。

## 作者

数据

参考文献

关键词

指标

脚注

IEEE个人帐户

采购明细

档案信息

需要帮忙？

更改用户名/密码

付款方式

通讯首选项

美国和加拿大: +1 800 678 4333

查看购买的文件

职业与教育

全球: +1 732 981 0060

技术兴趣

联系与支持

跟随



**IEEE Account**

- » [Change Username/Password](#)
- » [Update Address](#)

**Purchase Details**

- » [Payment Options](#)
- » [Order History](#)
- » [View Purchased Documents](#)

**Profile Information**

- » [Communications Preferences](#)
- » [Profession and Education](#)
- » [Technical Interests](#)

**Need Help?**

- » **US & Canada:** +1 800 678 4333
- » **Worldwide:** +1 732 981 0060
- » [Contact & Support](#)

[About IEEE Xplore](#) | [Contact Us](#) | [Help](#) | [Accessibility](#) | [Terms of Use](#) | [Nondiscrimination Policy](#) | [Sitemap](#) | [Privacy & Opting Out of Cookies](#)

A not-for-profit organization, IEEE is the world's largest technical professional organization dedicated to advancing technology for the benefit of humanity.  
© Copyright 2020 IEEE - All rights reserved. Use of this web site signifies your agreement to the terms and conditions.